

I n f o r m a t y k a w M e d y c y n i e - L a b o r a t o r i u m

Wykrywanie naczyń dna siatkówki oka - projekt

Kierunek/semestr: Informatyka/6

Grupa: L16

Jakub Kwiatkowski 145356

Paweł Strzelczyk 145217

1 Opis projektu.

Projekt został przygotowany w formie interaktywnego Jupyter Notebook.

Do przetwarzania obrazów oraz uczenia maszynowego wykorzystano język Python 3 oraz biblioteki:

- numpy,
- matplotlib,
- skimage,
- OpenCV,
- pandas,
- ipython (ipywidgets, IPython),
- scikit-learn,
- joblib.

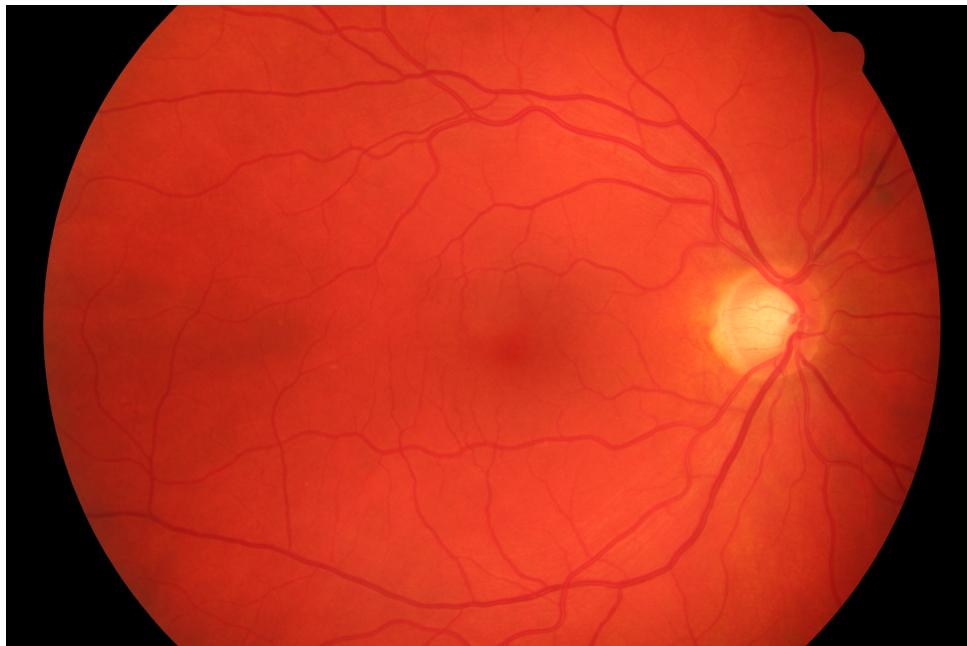
Do analizy przetwarzania obrazów oraz uczenia maszynowego skorzystano z bazy danych medycznych HRF (High-Resolution Fundus). Zawiera ona 45 zdjęć o wymiarach 3504×2336 px. W projekcie wykorzystano 15 zdjęć dna oka zdrowych pacjentów. Do każdego zdjęcia jest dostępna ręczna segmentacja oraz maska pola widzenia.

2 Opis wykorzystanych metod wykrywania naczyń dna siatkówki oka.

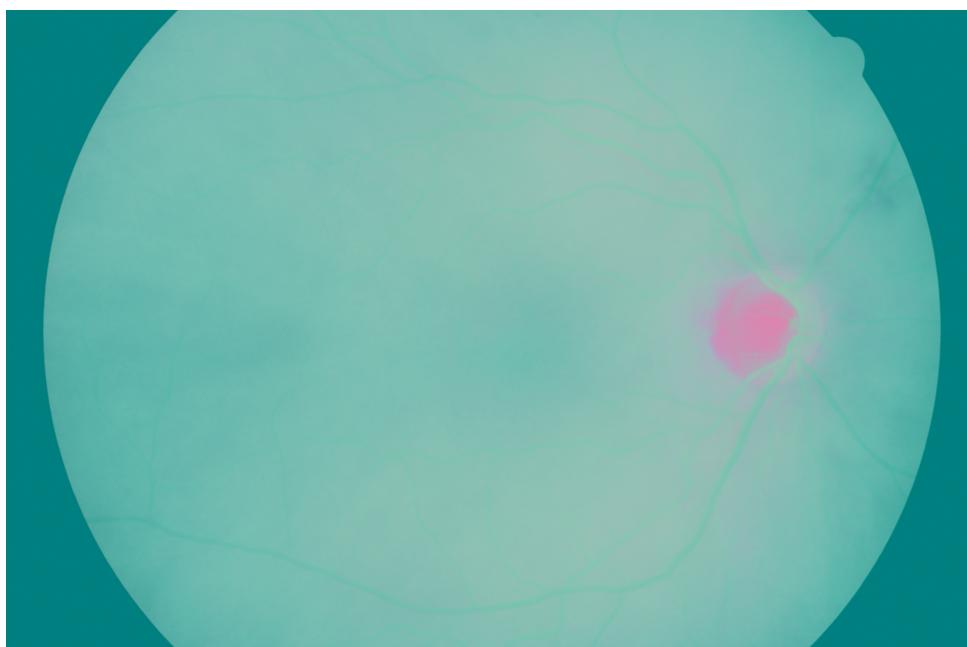
2.1 Przetwarzanie obrazu.

Algorytm przetwarzania.

Wczytanie obrazu.



Konwersja do przestrzeni barw CIELab. Konwersja w celu wyizolowania kanału 1 tejże przestrzeni, który dobrze odpowiada jasności obrazu.



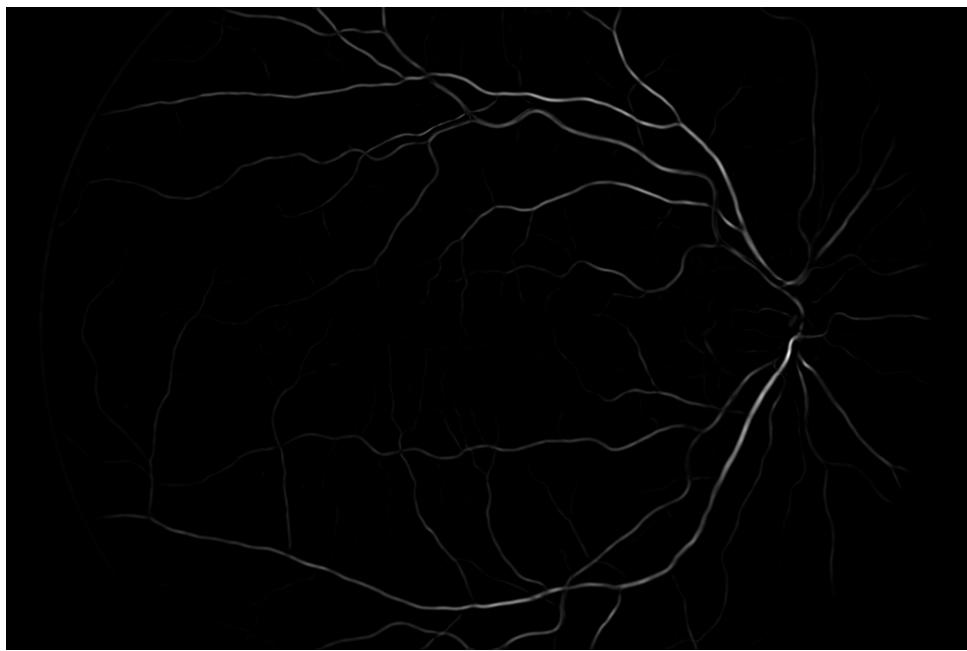
Wyrównanie histogramu. Zastosowano wariant CLAHE wyrównania histogramu obrazu z progiem 3.



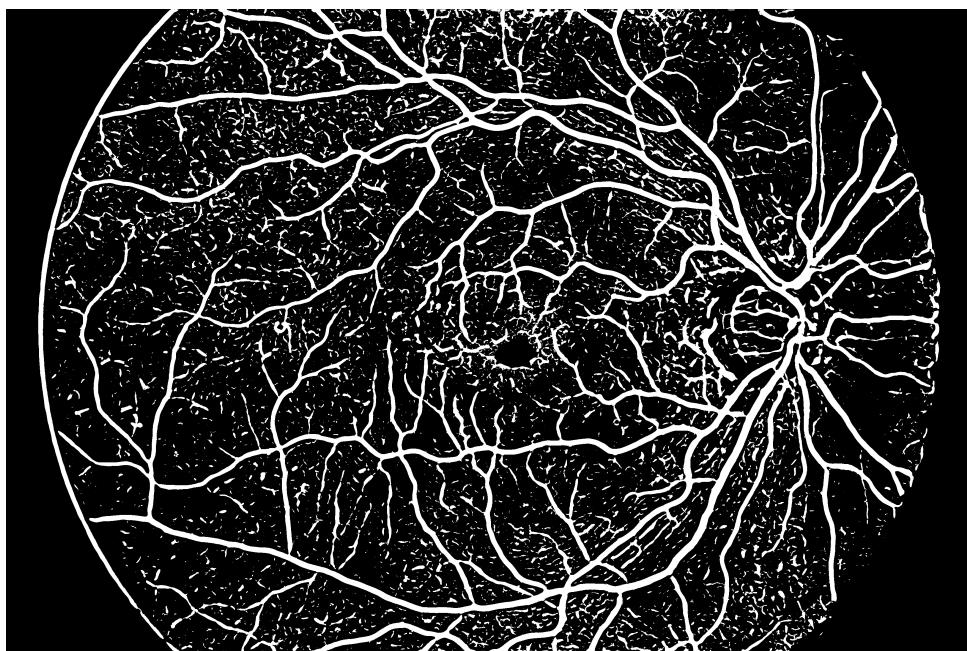
Ekstrakcja kanału koloru zielonego. Naturalnie czerwone naczynia krwionośne są dobrze widoczne w zielonym kanale obrazu.



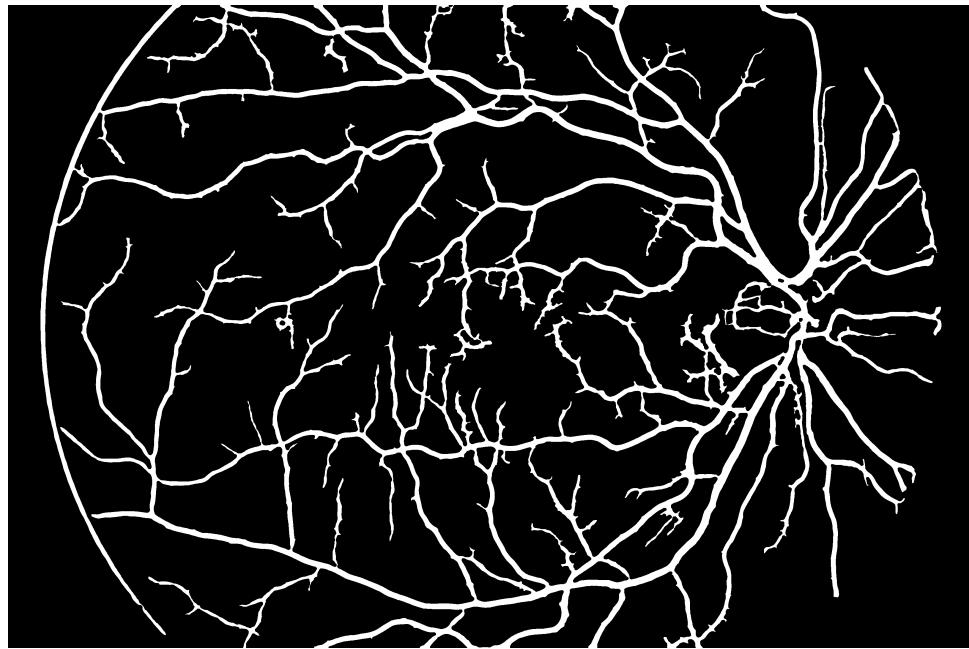
Filtr Frangi. Zastosowano filtr Frangi dostępny w bibliotece scikit-image.



Filtr progowy. Binarny przydział pikseli do klas - stwierdzenie czy dany piksel jest naczyniem. Jako próg odcięcia przyjęto średnią arytmetyczną wartość pikseli na obrazie, pomnożoną razy 0,45.



Przetwarzanie końcowe. Zastosowanie wbudowanych funkcji usuwania małych obiektów oraz dziur, następnie przeprowadzenie erozji oraz domknięcia morfologicznego.



Uzasadnienie. Zdecydowano się na zastosowanie filtru Frangi'ego, ponieważ jest to dedykowana metoda wykrywania naczyń krwionośnych. Przetwarzanie wstępne miało na celu maksymalne zwiększenie kontrastu pomiędzy naczyniami a tłem. Przetwarzanie końcowe polegało na usunięciu niedoskonałości powstających w wyniku przeprowadzenia filtrowania, m.in. na pozostawieniu jedynie ciągłych elementów o określonej powierzchni.

Miary statystyczne.

nr obrazu	trafność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
1	0,9258	0,7985	0,9403	0,8665	0,9258	0,8130
2	0,9125	0,8727	0,9169	0,8945	0,9125	0,8770
3	0,9331	0,7923	0,9497	0,8674	0,9331	0,8089
4	0,9300	0,8613	0,9372	0,8984	0,9300	0,8685
5	0,9582	0,8381	0,9701	0,9017	0,9582	0,8500
6	0,9516	0,8600	0,9620	0,9095	0,9516	0,8703
7	0,9550	0,8608	0,9642	0,9110	0,9550	0,8700
8	0,9491	0,8546	0,9596	0,9056	0,9491	0,8651
9	0,9389	0,8414	0,9471	0,8927	0,9389	0,8496
10	0,9394	0,8185	0,9508	0,8822	0,9394	0,8299
11	0,9458	0,8942	0,9511	0,9222	0,9458	0,8995
12	0,9535	0,8793	0,9622	0,9198	0,9535	0,8880
13	0,9253	0,8914	0,9285	0,9098	0,9253	0,8946
14	0,9235	0,8564	0,9299	0,8924	0,9235	0,8629
15	0,9387	0,9273	0,9396	0,9335	0,9387	0,9283
ŚREDNIA	0,9387	0,8565	0,9473	0,9005	0,9387	0,8650

2.2 Uczenie maszynowe - klasyfikator kNN.

Podział obrazu na wycinki. Z uwagi na zasoby pamięciowe oraz dostępną moc obliczeniową, zdecydowano się na zmniejszenie wymiarów obrazów źródłowych do 20% oryginalnej wielkości. Następnie dokonano podziału obrazu na wycinki o wymiarach 5×5 , co jeden piksel (nakładające się). W tym celu skorzystano z funkcji dostępnej w bibliotece numpy - `stride_tricks.as_strided()`.

Ekstrakcja cech. Do opisu wycinków skorzystano z:

- średniej kolorów,
- wariancji kolorów,
- pierwszych siedmiu momentów Hu.

Metoda uczenia maszynowego. Jako metody uczenia maszynowego zdecydowano się na wykorzystanie klasyfikatora k najbliższych sąsiadów. Na podstawie jednego obrazu stworzono zbiór treningowy oraz testowy. Na ich podstawie nauczono oraz przetestowano model. Przyjęte parametry klasyfikatora to liczba sąsiadów = 3, liczba klas decyzyjnych= 2, miara odległości - euklidesowa.

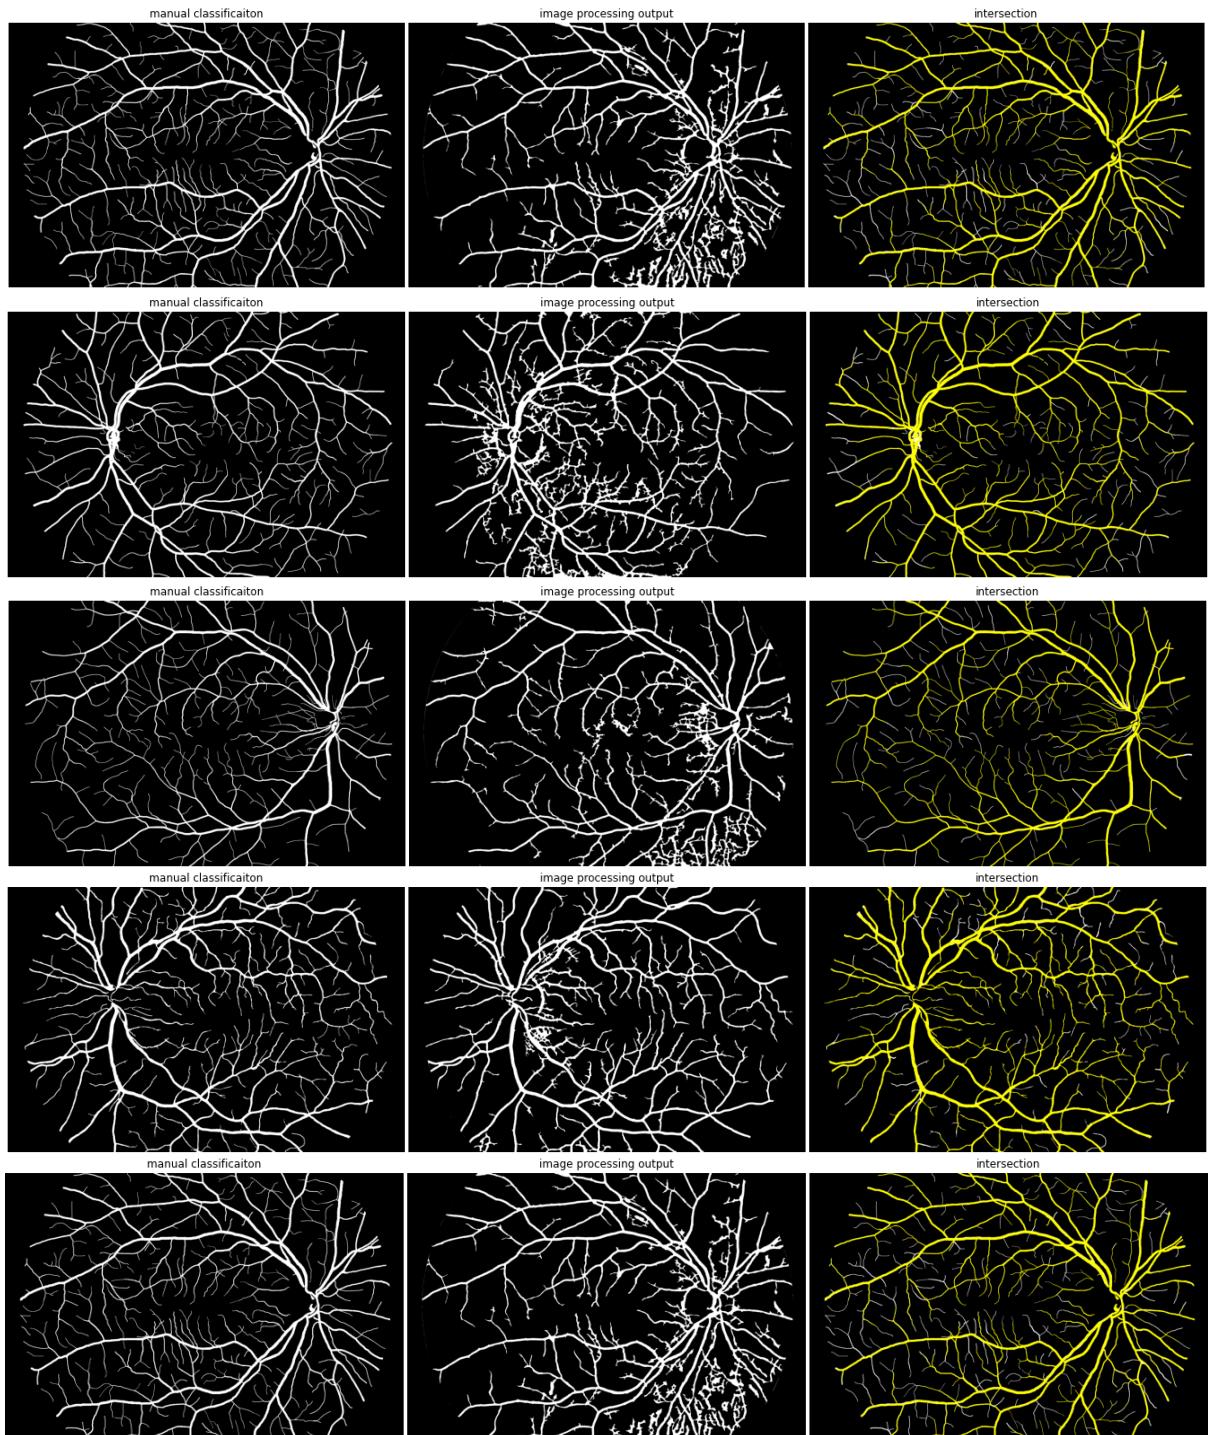
Ocena działania klasyfikatora na zbiorze hold-out. Wynik działania klasyfikatora - miary statystyczne zbioru hold-out testowego oraz przewidywanego.

- trafność - 0,9609
- czułość - 0,8666
- specyficzność - 0,9777
- średnia G - 0,9204

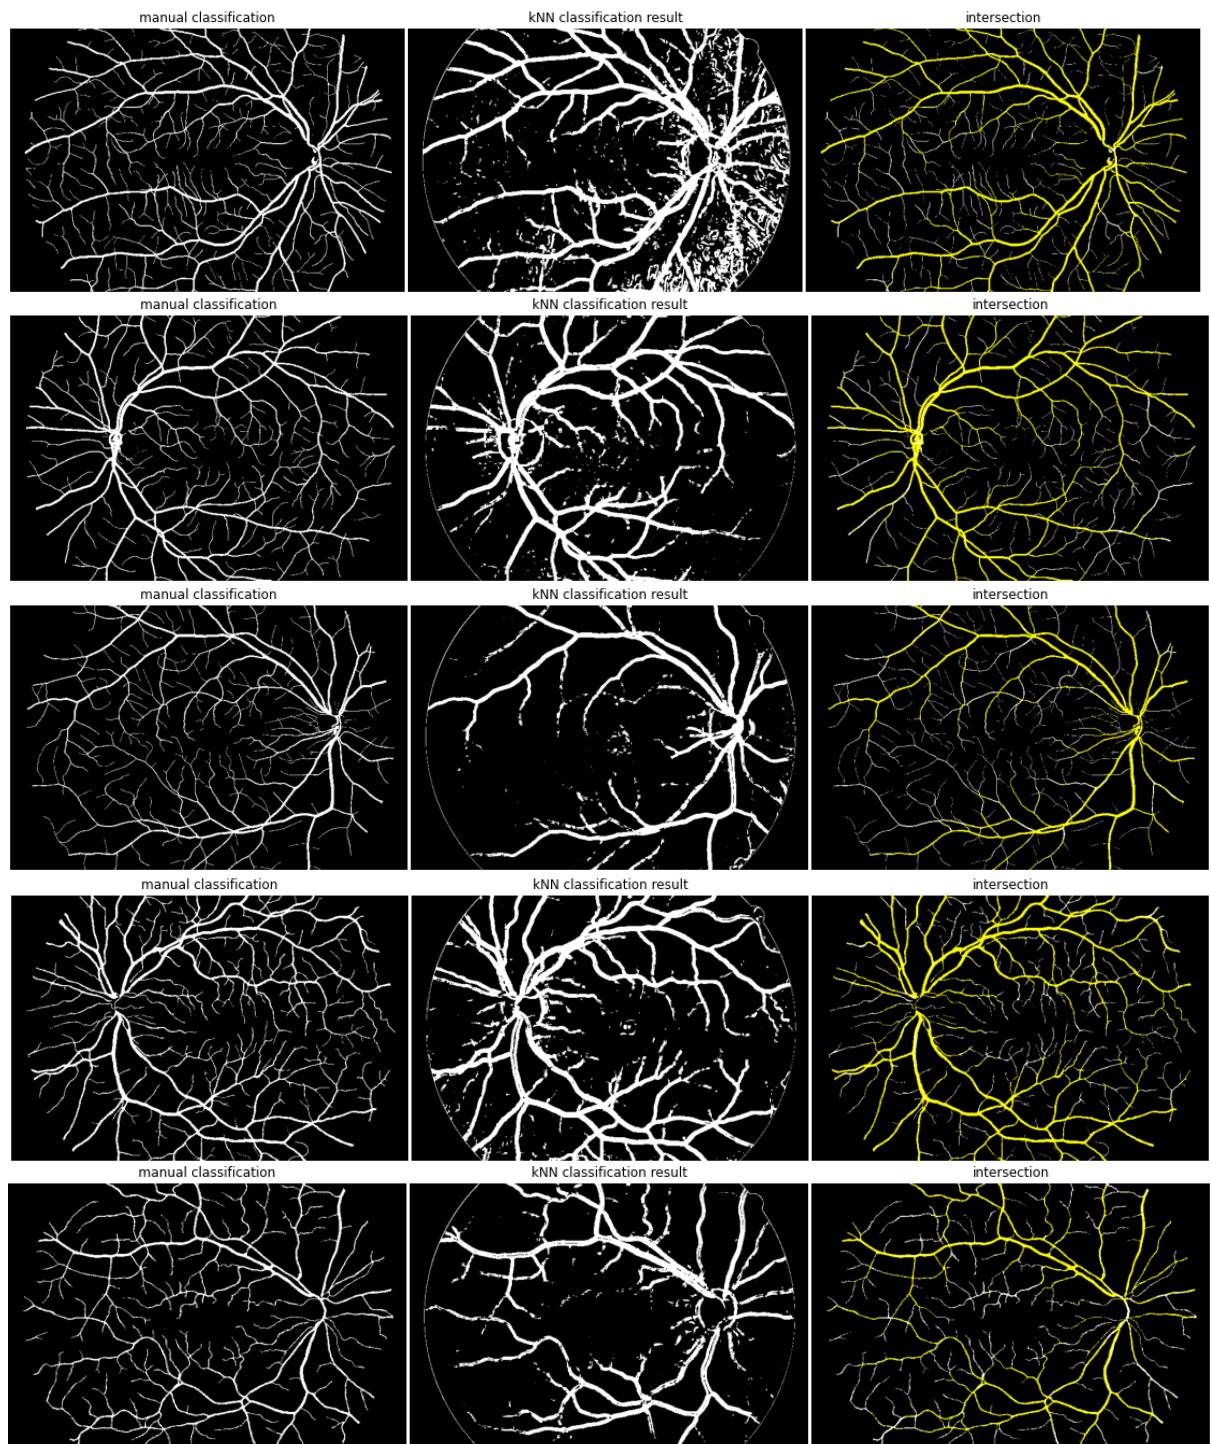
Uzasadnienie. Wybór klasyfikatora kNN był pokierowany przede wszystkim poprawnie oznaconym zbiorem danych, tzn. dla każdego piksela można stwierdzić, czy przynależy on do naczynia krwionośnego. Ponadto, zbiór danych jest pozbawiony dużych odchyleń - takie parametry jak średnia kolorów lub wariancja, zawierają się w określonym przedziale w przypadku czarno-białego zdjęcia. Klasyfikator ten umożliwia także manipulowanie liczbą k, która ma znaczący wpływ na jakość klasyfikacji, dając możliwość znalezienia najlepszej jej wartości.

3 Wyniki.

3.1 Przetwarzanie obrazów.



3.2 Uczenie maszynowe.



4 Analiza porównawcza.

4.1 Przetwarzanie obrazów.

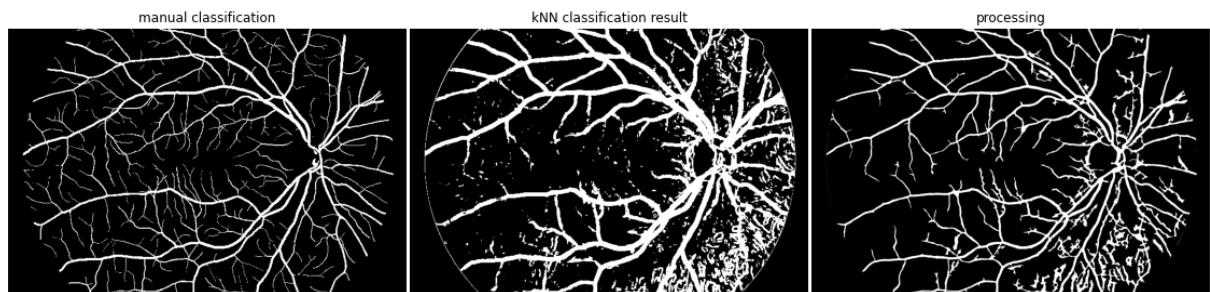
nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
1	0,9258	0,7985	0,9403	0,8665	0,9258	0,8130
4	0,9300	0,8613	0,9372	0,8984	0,9300	0,8685
9	0,9389	0,8414	0,9471	0,8927	0,9389	0,8496
12	0,9535	0,8793	0,9622	0,9198	0,9535	0,8880
15	0,9387	0,9273	0,9396	0,9335	0,9387	0,9283

4.2 Uczenie maszynowe.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
1	0,8350	0,7595	0,8435	0,8004	0,8350	0,7681
4	0,8867	0,7108	0,9051	0,8021	0,8867	0,7291
9	0,9133	0,5818	0,9412	0,7400	0,9133	0,6098
12	0,8779	0,7504	0,8929	0,8185	0,8779	0,7654
15	0,8976	0,5825	0,9244	0,7338	0,8976	0,6093

4.3 Porównanie metod segmentacji.

Obraz nr 1.



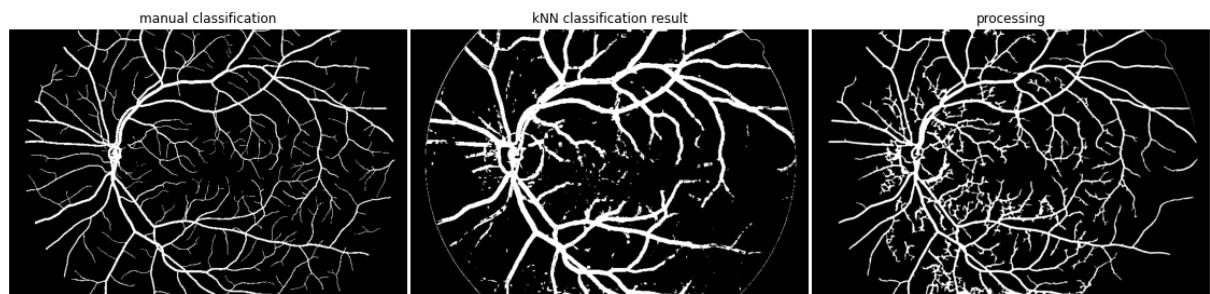
Miary oceny przetwarzania.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
1	0,9258	0,7985	0,9403	0,8665	0,9258	0,8130

Miary oceny uczenia maszynowego.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
1	0,8350	0,7595	0,8435	0,8004	0,8350	0,7681

Obraz nr 4.



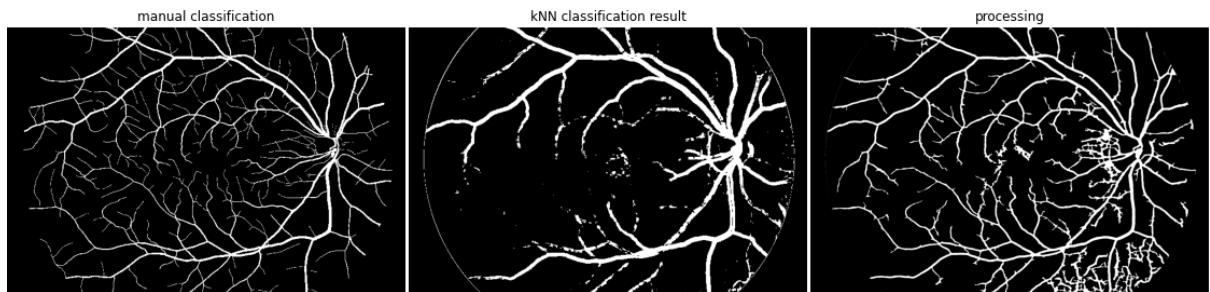
Miary oceny przetwarzania.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
4	0,9300	0,8613	0,9372	0,8984	0,9300	0,8685

Miary oceny uczenia maszynowego.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
4	0,8867	0,7108	0,9051	0,8021	0,8867	0,7291

Obraz nr 9.



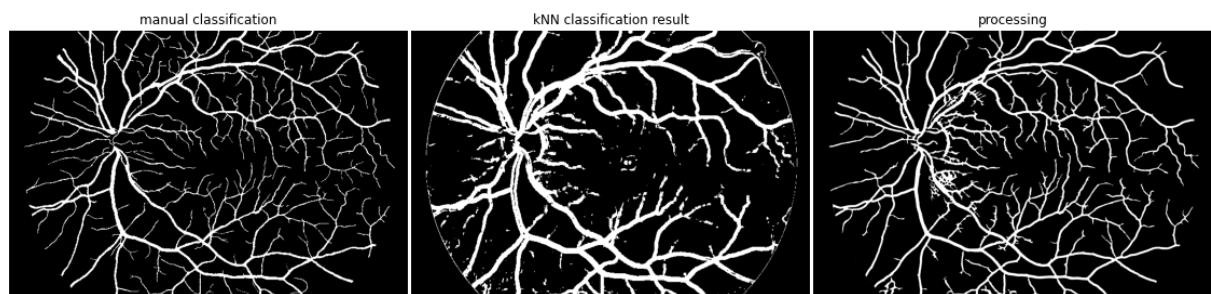
Miary oceny przetwarzania.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
9	0,9389	0,8414	0,9471	0,8927	0,9389	0,8496

Miary oceny uczenia maszynowego.

nr obrazu	trąfność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
9	0,9133	0,5818	0,9412	0,7400	0,9133	0,6098

Obraz nr 12.



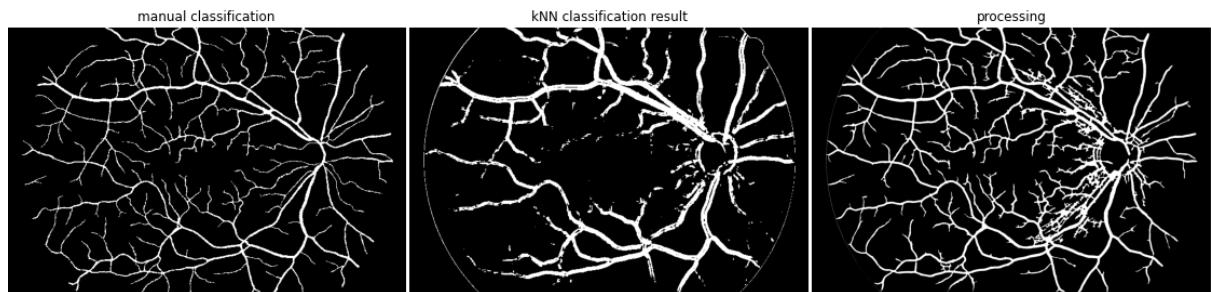
Miary oceny przetwarzania.

nr obrazu	trafność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
12	0,9535	0,8793	0,9622	0,9198	0,9535	0,8880

Miary oceny uczenia maszynowego.

nr obrazu	trafność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
12	0,8779	0,7504	0,8929	0,8185	0,8779	0,7654

Obraz nr 15.



Miary oceny przetwarzania.

nr obrazu	trafność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
15	0,9387	0,9273	0,9396	0,9335	0,9387	0,9283

Miary oceny uczenia maszynowego.

nr obrazu	trafność	czułość	specyficzność	średnia G	ważona czułość	ważona specyficzność
15	0,8976	0,5825	0,9244	0,7338	0,8976	0,6093